

Titanic Survival Prediction

Machine Learning · Deep Learning · Kaggle Competition

Francisco Ardiles Miranda

Analista de Datos Profesional Junior · Certificado Google

891	38.4%	0.884	5
Pasajeros Train	Tasa Supervivencia	AUC DL (CV Media)	Folds CV

Fase	Descripcion
1. Carga	Deteccion automatica de CSV · train/test/gender_submission
2. Calidad	Nulos: Age 19.9% · Cabin 77.1% · Embarked 0.2%
3. EDA	Supervivencia por Sexo, Clase, Edad, Familia, Tarifa
4. Feature Eng.	Title, FamilySize, IsAlone, AgeBand, FareBand
5. Modelo DL	Red Neuronal con 5-Fold CV · EarlyStopping · ReduceLROnPlateau
6. Submission	418 predicciones exportadas a submission.csv para Kaggle

GitHub: franciscoantonioardiles-ctrl · Kaggle: panchoardiles

1. Analisis Exploratorio de Datos (EDA)

El dataset de entrenamiento contiene **891 pasajeros** con 12 variables. Solo el **38.4% sobrevivio** al naufragio. El analisis revela los factores historicamente documentados: las **mujeres** tuvieron tasa de supervivencia significativamente mayor que los hombres (protocolo "mujeres y ninos primero"). Los pasajeros de **1a clase** tuvieron acceso prioritario a los botes salvavidas. Los **ninos** (Age < 12) presentan mayor supervivencia independiente del sexo. Los pasajeros que viajan **con familia pequena** (2-4 miembros) sobrevivieron mas que quienes viajaban solos o en grupos muy grandes.




Fig. 1 — EDA completo: supervivencia global (38.4%), por sexo, clase, distribucion de edad, tamano de familia y banda de tarifa.

2. Calidad del Dato y Correlaciones

El dataset presenta tres variables con valores nulos: **Age** (19.9% — 177 registros) imputada con la mediana por grupo, **Cabin** (77.1% — 687 registros) descartada por alta cardinalidad, y **Embarked** (0.2% — 2 registros) imputada con la moda (Southampton). La matriz de correlacion confirma que **Sex** y **Pclass** son las variables con mayor correlacion con la supervivencia, seguidas de **Fare**. La variable **FamilySize** (derivada) muestra correlacion positiva moderada, validando su inclusion como feature engineered.




Fig. 2 — (Izq.) Matriz de correlacion triangular inferior de variables numericas. (Der.) Porcentaje de valores nulos por variable: Cabin descartada, Age y Embarked imputadas.

3. Feature Engineering

Se crean 5 nuevas variables derivadas que mejoran la capacidad predictiva del modelo. **Title** (extraído del nombre) captura el estatus social y sexo del pasajero de forma mas granular que la variable Sex original: "Mrs" y "Miss" tienen supervivencia cercana al 70-75%, "Master" (ninos varones) al 57%, mientras "Mr" cae al 16%. **FamilySize** = SibSp + Parch + 1 revela que familias de 2-4 miembros tienen la mayor supervivencia. **IsAlone** (binaria) captura el efecto de viajar sin acompañantes. **AgeBand** y **FareBand** discretizan las variables continuas reduciendo el ruido en el modelo.

Feature Engineering — Nuevas Variables Derivadas · Titanic Francisco Ardiles Miranda · Analista de Datos Junior · Certificado Google




Fig. 3 — Feature Engineering: supervivencia por titulo extraído del nombre (izq.), por banda de edad (centro) y comparacion viaje solo vs en familia (der.).

4. Modelo — Random Forest y Curva ROC

El **Random Forest** (200 arboles, max_depth=6) se usa como modelo de referencia para evaluar la importancia de features. **Sex** es la variable mas importante (>0.30), seguida de **Fare** y **Age** — consistente con el analisis EDA. La **Curva ROC** con $AUC = 0.87$ confirma que el modelo supera ampliamente al clasificador aleatorio ($AUC = 0.5$) y al baseline de solo predecir mujeres ($AUC \sim 0.765$). El modelo principal del proyecto es la **Red Neuronal con 5-Fold Cross-Validation** que alcanza AUC media de 0.884.




Fig. 4 — (Izq.) Importancia de features del Random Forest: Sexo domina la prediccion. (Der.) Curva ROC con $AUC = 0.87$ superando el baseline.

5. Deep Learning — 5-Fold Cross-Validation

El modelo principal es una **Red Neuronal** entrenada con **Stratified 5-Fold Cross-Validation** para garantizar evaluacion robusta con solo 891 registros. Cada fold usa EarlyStopping (patience=20) y ReduceLROnPlateau para convergencia optima. El **AUC medio de 0.884** con baja varianza entre folds (0.867 - 0.902) indica un modelo estable y generalizable. El F1-Score medio de 0.795 refleja buen balance entre precision y recall en la clase minoritaria (supervivientes, 38.4% del dataset). Las predicciones finales sobre 418 pasajeros del test set se exportan en formato submission.csv para Kaggle.

Evaluacion Deep Learning — 5-Fold Cross-Validation · Titanic Francisco Ardiles Miranda · Analista de Datos Junior · Certificado Google




Fig. 5 — AUC (izq.) y F1-Score (der.) por fold de la Red Neuronal. Linea blanca = media. Varianza baja indica modelo estable.

6. Evaluacion Final y Submission Kaggle




Fig. 6 — (Izq.) Matriz de confusion del Random Forest. (Der.) Comparacion de AUC: Red Neuronal vs RF vs Baseline (solo mujeres).

Conclusiones y Aprendizajes

#	Hallazgo	Aprendizaje / Mejora Futura
1	Sex es el predictor mas importante	Confirma el protocolo historico "mujeres y ninos primero"
2	AUC DL = 0.884 supera baseline 0.765	El feature engineering aporta +11 puntos de AUC
3	Cabin descartada (77% nulos)	Podria recuperarse como indicador de cubierta del barco
4	Val_loss inestable en Fold 2	Corregido: normalizar Fare con RobustScaler antes del entrenamiento
5	Submission.csv generado (418 registros)	Listo para envio a Kaggle y evaluacion publica

Francisco Ardiles Miranda · Analista de Datos Profesional Junior · Certificado Google · GitHub: franciscoantonioardiles-ctrl · Kaggle: panchoardiles